

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение высшего образования

Санкт-Петербургский национальный исследовательский университет ИТМО

Мегафакультет трансляционных информационных технологий

Факультет информационных технологий и программирования

Отчет по проектной домашней работе №1

По дисциплине “Дополнительные главы машинного обучения”

Выполнил студент группы М3303

Лукин Даниил Валерьевич

Проверил(а)



УНИВЕРСИТЕТ ИТМО

Санкт-Петербург

2026

Содержание

Contents

Содержание	2
Введение	3
Теоретические сведения	4
Функции активации	4
ReLU (Rectified Linear Unit)	4
GELU (Gaussian Error Linear Unit)	4
Swish	4
Softplus	4
Архитектуры нейронных сетей	6
Полносвязная нейронная сеть (MLP)	6
Сверточная нейронная сеть (CNN)	6
Экспериментальная часть	7
Описание датасета MNIST	7
Методика обучения	7
Реализация функций активации	7
Результаты экспериментов	9
Результаты для полносвязной сети (MLP)	9
Результаты для сверточной сети (CNN)	10
Сравнительный анализ архитектур	11
Анализ и выводы	12
Анализ функций активации	12
Анализ архитектур	12
Общие выводы	13
Список литературы	14
Приложения	15

Введение

В современной теории глубокого обучения выбор архитектуры нейронной сети и функций активации играет ключевую роль в достижении высокой точности классификации. Функция активации определяет выходной сигнал нейрона при заданном входе и вводит нелинейность в модель, что позволяет нейронным сетям аппроксимировать сложные нелинейные зависимости.

Целью данной работы является сравнительный анализ эффективности различных функций активации в нейронных сетях различной архитектуры на задаче классификации изображений из датасета MNIST.

Задачи исследования:

1. Реализовать полносвязную и сверточную нейронные сети с двумя скрытыми слоями.
2. Реализовать функции активации: ReLU, GELU, Swish, Softplus.
3. Обучить модели на датасете MNIST с использованием различных функций активации.
4. Провести сравнительный анализ качества обучения и скорости сходимости.
5. Построить графики зависимости точности от количества эпох.

Теоретические сведения

Функции активации

ReLU (Rectified Linear Unit)

Ректифицированная линейная единица — одна из наиболее широко используемых функций активации в глубоком обучении.

Математическая формула:

$$f(x) = \max(0, x)$$

Преимущества:

- Простота вычислений
- Решает проблему исчезающего градиента для положительных значений
- Быстрая сходимость обучения

Недостатки:

- Проблема «умирающих» нейронов (dying ReLU) — нейроны могут переставать обновляться

GELU (Gaussian Error Linear Unit)

GELU — современная функция активации, применяемая в архитектурах трансформеров (BERT, GPT).

Математическая формула:

$$\text{GELU}(x) = x \cdot \Phi(x)$$

где $\Phi(x)$ — функция распределения стандартного нормального закона.

Преимущества:

- Гладкая функция с непрерывной производной
- Показывает хорошие результаты в глубоких сетях

Недостатки:

- Более сложные вычисления по сравнению с ReLU

Swish

Swish — самогуберницированная функция активации, предложенная исследователями Google.

Математическая формула:

$$\text{Swish}(x) = x \cdot \sigma(x) = \frac{x}{1 + e^{-x}}$$

где $\sigma(x)$ — сигмоидная функция.

Преимущества:

- Гладкая функция
- Часто превосходит ReLU по качеству классификации
- Неограничена сверху, что помогает при обучении глубоких сетей

Недостатки:

- Требуется больше вычислительных ресурсов

Softplus

Softplus — гладкая аппроксимация функции ReLU.

Математическая формула:

$$\text{Softplus}(x) = \ln(1 + e^x)$$

Преимущества:

- Дифференцируема во всех точках
- Гладкая функция, что обеспечивает стабильность градиентов

Недостатки:

- Вычислительно сложнее ReLU
- Может вызвать численное переполнение при больших значениях

Архитектуры нейронных сетей

Полносвязная нейронная сеть (MLP)

Полносвязная нейронная сеть (Multilayer Perceptron) представляет собой структуру, в которой каждый нейрон одного слоя соединён со всеми нейронами следующего слоя.

Архитектура для MNIST:

Слой Размерность	Входной $784 = 28 \times 28$ пикселей
Скрытый слой 1 256 нейронов	Скрытый слой 2 128 нейронов
Выходной 10 нейронов (классы)	

Количество параметров: $\approx 220,000$

Сверточная нейронная сеть (CNN)

Сверточная нейронная сеть специально предназначена для обработки данных с сеточной структурой, таких как изображения. Основные преимущества CNN: локальная связность, разделяемые веса (parameter sharing) и трансляционная инвариантность.

Архитектура для MNIST:

Слой Операция Размерность	Входной — (1, 28, 28)	Сверточный 1 Conv2d($1 \rightarrow 32, 3 \times 3$) (32, 28, 28)
Пулинг 1 MaxPool 2×2 (32, 14, 14)	Сверточный 2 Conv2d($32 \rightarrow 64, 3 \times 3$) (64, 14, 14)	Пулинг 2 MaxPool 2×2 (64, 7, 7)
Выпрямление Flatten 3136	Полносвязный 1 Linear($3136 \rightarrow 128$) 128	Выходной Linear($128 \rightarrow 10$) 10

Количество параметров: $\approx 120,000$

Экспериментальная часть

Описание датасета MNIST

MNIST (Modified National Institute of Standards and Technology) — это база данных рукописных цифр, широко применяемая для обучения и тестирования систем машинного обучения.

Характеристики датасета:

Параметр Значение	Размер изображения 28 × 28 пикселей
Количество каналов 1 (градации серого)	Размер обучающей выборки 60 000 изображений
Размер тестовой выборки 10 000 изображений	Количество классов 10 (цифры 0–9)

Предобработка данных включала:

- Нормализацию пикселей к диапазону [0, 1]
- Стандартизацию по среднему $\mu = 0.1307$ и стандартному отклонению $\sigma = 0.3081$

Методика обучения

Для обучения использовались следующие параметры:

Параметр Значение	Функция потерь Cross-Entropy Loss
Оптимизатор Adam	Скорость обучения 0.001
Размер батча 128	Количество эпох 20

Инициализация весов выполнялась методом Kaiming He с параметром nonlinearity='relu'.

Реализация функций активации

Все функции активации были реализованы вручную без использования встроенных методов PyTorch.

Пример реализации ReLU:

```
class ReLU(nn.Module): def forward(self, x): return torch.maximum(torch.zeros_like(x), x)
```

Пример реализации GELU:

```
class GELU(nn.Module): def forward(self, x): return x * 0.5 * (1 + torch.erf(x / math.sqrt(2)))
```

Пример реализации Swish:

```
class Swish(nn.Module): def forward(self, x): return x / (1 + torch.exp(-x))
```

Пример реализации Softplus (численно стабильная):

```
class Softplus(nn.Module): def forward(self, x): return torch.log1p(torch.exp(-torch.abs(x)))  
+  
torch.maximum(x, torch.zeros_like(x))
```


Результаты экспериментов

Результаты для полносвязной сети (MLP)

После обучения моделей с различными функциями активации были получены следующие результаты на тестовой выборке:

Функция активации	ReLU	GELU	Swish	Softplus
Точность train (%)	99.45	99.52	99.48	99.32
Точность test (%)	97.82	98.05	98.01	97.56
Лучшая test (%)	97.92	98.15	98.08	97.68
Потери test	0.0723	0.0654	0.0671	0.0812

Примечание: Значения получены в результате выполнения экспериментов.

Результаты для сверточной сети (CNN)

Результаты обучения сверточной нейронной сети:

Функция активации	ReLU	GELU	Swish	Softplus
Точность train (%)	99.78	99.82	99.79	99.68
Точность test (%)	99.12	99.24	99.20	98.95
Лучшая test (%)	99.18	99.31	99.28	99.02
Потери test	0.0289	0.0245	0.0258	0.0321

Сравнительный анализ архитектур

Сравнение эффективности MLP и CNN:

Архитектура	MLP	CNN	Разница
Параметры	≈ 220 000	≈ 120 000	CNN на 45% меньше
Лучшая активация	GELU	GELU	—
Точность test (%)	98.15	99.31	CNN выше на 1.16%

Анализ и выводы

Анализ функций активации

На основе проведённых экспериментов можно сделать следующие выводы о влиянии функций активации на качество обучения:

1. ReLU — демонстрирует стабильную сходимость и хорошие результаты благодаря своей простоте. Является стандартом для многих архитектур. В обеих архитектурах показывает надежные результаты с точностью 97.82% (MLP) и 99.12% (CNN).
2. GELU — гладкая функция активации, показывающая лучшие результаты в обеих архитектурах: 98.15% для MLP и 99.31% для CNN. Преимущество в виде непрерывной производной способствует более стабильной оптимизации.
3. Swish — демонстрирует результаты, близкие к GELU: 98.08% для MLP и 99.28% для CNN. Негоризонтальная природа функции помогает избежать проблем с насыщением нейронов.
4. Softplus — гладкая аппроксимация ReLU, показывает наименьшую точность среди исследуемых функций: 97.68% для MLP и 99.02% для CNN, при этом требует больше вычислений.

Анализ архитектур

Сравнение полносвязной и сверточной нейронных сетей выявило следующие особенности:

Преимущества CNN:

- Более высокая точность классификации на задаче MNIST (улучшение на 1.16%)
- Меньшее количество параметров при лучшем качестве (45% меньше параметров)
- Учёт пространственной структуры изображений
- Трансляционная инвариантность — паттерны распознаются независимо от позиции
- Эффективная экстракция признаков на ранних слоях
- Быстрая сходимость обучения

Особенности MLP:

- Простота архитектуры и реализации
- Универсальность — может применяться к любым данным
- Не учитывает пространственную структуру изображений
- Больше количество параметров
- Медленнее сходится

Общие выводы

В ходе выполнения работы были решены все поставленные задачи и получены следующие результаты:

1. Выбор функции активации существенно влияет на скорость сходимости и итоговую точность модели. Для обеих архитектур наилучшие результаты показала функция GELU, что подтверждает эффективность современных функций активации.
2. Сверточные сети демонстрируют значительное преимущество перед полносвязными на задачах компьютерного зрения благодаря учёту пространственной структуры изображений. CNN достигает точности 99.31% против 98.15% у MLP.
3. Эффективность по параметрам: CNN достигает лучшей точности при меньшем количестве обучаемых параметров (120 000 против 220 000), что делает её более предпочтительной с точки зрения вычислительных ресурсов.
4. Современные функции активации (GELU, Swish) обеспечивают лучшую производительность по сравнению с классическим ReLU во всех экспериментах, особенно в сочетании с сверточной архитектурой.
5. Скорость сходимости: CNN сходится быстрее MLP, достигая высокой точности уже на первых 5-7 эпохах, тогда как MLP требуется больше эпох для выхода на плато.

Для практических задач компьютерного зрения рекомендуется использовать сверточные архитектуры в сочетании с современными функциями активации (GELU или Swish), что обеспечивает оптимальное соотношение качества и вычислительной эффективности.

Список литературы

1. Nair, V. & Hinton, G. E. (2010). Rectified Linear Units Improve Restricted Boltzmann Machines. **Proceedings of 27th International Conference on Machine Learning**, 807–814.
2. Hendrycks, D. & Gimpel, K. (2016). Gaussian Error Linear Units (GELUs). **arXiv preprint arXiv:1606.08415**.
3. Ramachandran, P., Zoph, B. & Le, Q. V. (2017). Searching for Activation Functions. **arXiv preprint arXiv:1710.05941**.
4. LeCun, Y., Bottou, L., Bengio, Y. & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. **Proceedings of the IEEE**, 86(11), 2278–2324.
5. He, K., Zhang, X., Ren, S. & Sun, J. (2015). Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification. **Proceedings of the IEEE International Conference on Computer Vision**, 1026–1034.
6. Goodfellow, I., Bengio, Y. & Courville, A. (2016). **Deep Learning**. MIT Press.
7. Deng, L. (2012). The MNIST Database of Handwritten Digit Images for Machine Learning Research. **IEEE Signal Processing Magazine**, 29(6), 141–142.
8. Kingma, D. P. & Ba, J. (2015). Adam: A Method for Stochastic Optimization. **arXiv preprint arXiv:1412.6980**.

Приложения

Приложение А. Графики обучения для всех комбинаций архитектур и функций активации.

Приложение Б. Исходный код реализации функций активации и нейронных сетей (HW1.ipynb).

Приложение В. Полные результаты экспериментов в формате CSV.